

Haskell na produkcji

czyli czy warto sięgać po niestandardowe narzędzia

Tomasz Tylec

11 listopada 2018

IF Research Polska (Gdańsk) / Mazars-Zettafox (Paris) | tomasz.tylec@ifresearch.pl

Reguły klasyfikujące

Implementacja w Haskellu

- Dlaczego Haskell?

- Kluczowe elementy

- Dlaczego nie Python

Integracja z ekosystemem Pythona

Podsumowanie

Reguły klasyfikujące

Definicja

Regułą nazywamy predykat, wyrażenie logiczne, które każdemu elementowi w zbiorze danych przypisuje wartość *prawda* lub *fałsz*.

Przykład

Dane:

| index | A | B | C |
|-------|--------|------|------|
| 0 | low | high | low |
| 1 | low | low | low |
| 2 | high | low | high |
| 3 | medium | low | high |

Definicja

Regułą nazywamy predykat, wyrażenie logiczne, które każdemu elementowi w zbiorze danych przypisuje wartość *prawda* lub *fałsz*.

Przykład

Dane:

| index | A | B | C |
|-------|--------|------|------|
| 0 | low | high | low |
| 1 | low | low | low |
| 2 | high | low | high |
| 3 | medium | low | high |

Reguła: $A \in \{\text{low}, \text{medium}\} \wedge B \in \{\text{low}\}$

Rozważać będziemy reguły postaci:

$$c_1 \wedge c_2 \wedge \dots \wedge c_n,$$

gdzie c_i jest postaci $X \in \{\dots\}$, lub $X \in (a, b)$.

Definicja

Regułą nazywamy predykat, wyrażenie logiczne, które każdemu elementowi w zbiorze danych przypisuje wartość *prawda* lub *fałsz*.

Przykład

Dane:

| index | A | B | C |
|-------|--------|------|------|
| 0 | low | high | low |
| 1 | low | low | low |
| 2 | high | low | high |
| 3 | medium | low | high |

Reguła: $A \in \{\text{low}, \text{medium}\} \wedge B \in \{\text{low}\}$

Rozważać będziemy reguły postaci:

$$c_1 \wedge c_2 \wedge \dots \wedge c_n,$$

gdzie c_i jest postaci $X \in \{\dots\}$, lub $X \in (a, b)$.

Reguły tworzą zbiór częściowo uporządkowany

$r \leq q$ jeśli dla każdego wiersza dla którego q jest prawdziwe, r też jest prawdziwe.

Przykłady:

- $A \in \{\text{low}\} \wedge B \in \{\text{low}\} \leq A \in \{\text{low, medium}\} \wedge B \in \{\text{low}\}$
- ale $A \in \{\text{low}\}$ oraz $B \in \{\text{high}\}$ jest są w relacji porządku.

Reguły tworzą zbiór częściowo uporządkowany

$r \leq q$ jeśli dla każdego wiersza dla którego q jest prawdziwe, r też jest prawdziwe.

Przykłady:

- $A \in \{\text{low}\} \wedge B \in \{\text{low}\} \leq A \in \{\text{low, medium}\} \wedge B \in \{\text{low}\}$
- ale $A \in \{\text{low}\}$ oraz $B \in \{\text{high}\}$ jest są w relacji porządku.

Reguły można ze sobą łączyć

Jeśli r, q są regułą to $r \wedge q$ też jest regułą. Wtedy $r \wedge q \leq r$ oraz $r \wedge q \leq q$.

Rozważać będziemy reguły postaci:

$$c_1 \wedge c_2 \wedge \dots \wedge c_n,$$

gdzie c_i jest postaci $X \in \{\dots\}$, lub $X \in (a, b)$.

Jeśli r, q są regułą to $r \vee q$ definiujemy jako najmniejszą (w sensie \leq) regułę spełniającą: $r \leq r \vee q$ oraz $q \leq r \vee q$.

Zadanie

Mając do dyspozycji zbiór sklasyfikowanych danych, znaleźć niewielki zbiór *najlepszych* reguł, względem pewnej funkcji oceniającej (*score function*).

Zaczynając od zbioru najogólniejszych nietrywialnych reguł a_1, a_2, \dots, a_k , tworzymy reguły postaci:

- $a_2 \wedge a_5$,
- $a_5 \wedge a_{10} \wedge a_{143}$,
- $a_{242} \wedge a_{743} \wedge a_{342} \wedge a_{1233}$,
- itd.

wybierając tylko te najlepsze.

Metoda I: przeszukiwanie drzewa

Zaczynając od zbioru najogólniejszych nietrywialnych reguł a_1, a_2, \dots, a_k , tworzymy reguły postaci:

- $a_2 \wedge a_5$,
- $a_5 \wedge a_{10} \wedge a_{143}$,
- $a_{242} \wedge a_{743} \wedge a_{342} \wedge a_{1233}$,
- itd.

wybierając tylko te najlepsze.

| index | A | B | C |
|-------|--------|------|------|
| 0 | low | high | low |
| 1 | low | low | low |
| 3 | high | low | high |
| 4 | medium | low | high |

$\text{Dom}(A) = \{\text{low, medium, high}\}$

$\text{Dom}(B) = \{\text{low, high}\}$

$\text{Dom}(C) = \{\text{low, medium, high}\}$

$a_1 = A \in \{\text{low, medium}\}, a_3 = B \in \{\text{low}\}$

$r = a_1 \wedge a_3 = A \in \{\text{low, medium}\} \wedge B \in \{\text{low}\}$

Metoda I: przeszukiwanie drzewa

Zaczynając od zbioru najogólniejszych nietrywialnych reguł a_1, a_2, \dots, a_k , tworzymy reguły postaci:

- $a_2 \wedge a_5$,
- $a_5 \wedge a_{10} \wedge a_{143}$,
- $a_{242} \wedge a_{743} \wedge a_{342} \wedge a_{1233}$,
- itd.

wybierając tylko te najlepsze.

| index | A | B | C |
|-------|--------|------|------|
| 0 | low | high | low |
| 1 | low | low | low |
| 3 | high | low | high |
| 4 | medium | low | high |

$\text{Dom}(A) = \{\text{low}, \text{medium}, \text{high}\}$

$\text{Dom}(B) = \{\text{low}, \text{high}\}$

$\text{Dom}(C) = \{\text{low}, \text{medium}, \text{high}\}$

$a_1 = A \in \{\text{low}, \text{medium}\}, a_3 = B \in \{\text{low}\}$

$r = a_1 \wedge a_3 = A \in \{\text{low}, \text{medium}\} \wedge B \in \{\text{low}\}$

Metoda I: przeszukiwanie drzewa

Zaczynając od zbioru najogólniejszych nietrywialnych reguł a_1, a_2, \dots, a_k , tworzymy reguły postaci:

- $a_2 \wedge a_5$,
- $a_5 \wedge a_{10} \wedge a_{143}$,
- $a_{242} \wedge a_{743} \wedge a_{342} \wedge a_{1233}$,
- itd.

wybierając tylko te najlepsze.

| index | A | B | C |
|-------|--------|------|------|
| 0 | low | high | low |
| 1 | low | low | low |
| 3 | high | low | high |
| 4 | medium | low | high |

$\text{Dom}(A) = \{\text{low, medium, high}\}$

$\text{Dom}(B) = \{\text{low, high}\}$

$\text{Dom}(C) = \{\text{low, medium, high}\}$

$a_1 = A \in \{\text{low, medium}\}, a_3 = B \in \{\text{low}\}$

$r = a_1 \wedge a_3 = A \in \{\text{low, medium}\} \wedge B \in \{\text{low}\}$

Metoda I: przeszukiwanie drzewa

Zaczynając od zbioru najogólniejszych nietrywialnych reguł a_1, a_2, \dots, a_k , tworzymy reguły postaci:

- $a_2 \wedge a_5$,
- $a_5 \wedge a_{10} \wedge a_{143}$,
- $a_{242} \wedge a_{743} \wedge a_{342} \wedge a_{1233}$,
- itd.

wybierając tylko te najlepsze.

| index | A | B | C |
|-------|--------|------|------|
| 0 | low | high | low |
| 1 | low | low | low |
| 3 | high | low | high |
| 4 | medium | low | high |

$\text{Dom}(A) = \{\text{low, medium, high}\}$

$\text{Dom}(B) = \{\text{low, high}\}$

$\text{Dom}(C) = \{\text{low, medium, high}\}$

$a_1 = A \in \{\text{low, medium}\}, a_3 = B \in \{\text{low}\}$

$r = a_1 \wedge a_3 = A \in \{\text{low, medium}\} \wedge B \in \{\text{low}\}$

Każdy element zbioru danych x_i odpowiada regule $r(x_i)$ – takiej, która wybiera dokładnie ten element. Tworzymy reguły postaci:

- $r(x_{10}) \vee r(x_{31})$,
- $r(x_1) \vee r(x_{45}) \vee r(x_{321}) \vee r(x_{1421}) \vee r(x_{2352}) \vee r(x_{31002})$
- itp.

wybierając najlepsze.

Metoda II: przeszukiwanie podzbiorów

Każdy element zbioru danych x_i odpowiada regule $r(x_i)$ – takiej, która wybiera dokładnie ten element. Tworzymy reguły postaci:

- $r(x_{10}) \vee r(x_{31})$,
- $r(x_1) \vee r(x_{45}) \vee r(x_{321}) \vee r(x_{1421}) \vee r(x_{2352}) \vee r(x_{31002})$
- itp.

wybierając najlepsze.

| index | A | B | C |
|-------|--------|------|------|
| 0 | low | high | low |
| 1 | low | low | low |
| 3 | low | low | high |
| 4 | medium | low | high |

$\text{Dom}(A) = \{\text{low}, \text{medium}, \text{high}\}$

$\text{Dom}(B) = \{\text{low}, \text{high}\}$

$\text{Dom}(C) = \{\text{low}, \text{medium}, \text{high}\}$

$a_1 = A \in \{\text{low}\} \wedge B \in \{\text{low}\} \wedge C \in \{\text{low}\}$

$a_2 = A \in \{\text{medium}\} \wedge B \in \{\text{low}\} \wedge C \in \{\text{high}\},$

$r = a_1 \wedge a_2 = A \in \{\text{low}, \text{medium}\} \wedge B \in \{\text{low}\} \wedge C \in \{\text{low}, \text{high}\}$

Metoda II: przeszukiwanie podzbiorów

Każdy element zbioru danych x_i odpowiada regule $r(x_i)$ – takiej, która wybiera dokładnie ten element. Tworzymy reguły postaci:

- $r(x_{10}) \vee r(x_{31})$,
- $r(x_1) \vee r(x_{45}) \vee r(x_{321}) \vee r(x_{1421}) \vee r(x_{2352}) \vee r(x_{31002})$
- itp.

wybierając najlepsze.

| index | A | B | C |
|-------|--------|------|------|
| 0 | low | high | low |
| 1 | low | low | low |
| 3 | low | low | high |
| 4 | medium | low | high |

$\text{Dom}(A) = \{\text{low}, \text{medium}, \text{high}\}$

$\text{Dom}(B) = \{\text{low}, \text{high}\}$

$\text{Dom}(C) = \{\text{low}, \text{medium}, \text{high}\}$

$a_1 = A \in \{\text{low}\} \wedge B \in \{\text{low}\} \wedge C \in \{\text{low}\}$

$a_2 = A \in \{\text{medium}\} \wedge B \in \{\text{low}\} \wedge C \in \{\text{high}\},$

$r = a_1 \wedge a_2 = A \in \{\text{low}, \text{medium}\} \wedge B \in \{\text{low}\} \wedge C \in \{\text{low}, \text{high}\}$

Metoda II: przeszukiwanie podzbiorów

Każdy element zbioru danych x_i odpowiada regule $r(x_i)$ – takiej, która wybiera dokładnie ten element. Tworzymy reguły postaci:

- $r(x_{10}) \vee r(x_{31})$,
- $r(x_1) \vee r(x_{45}) \vee r(x_{321}) \vee r(x_{1421}) \vee r(x_{2352}) \vee r(x_{31002})$
- itp.

wybierając najlepsze.

| index | A | B | C |
|-------|--------|------|------|
| 0 | low | high | low |
| 1 | low | low | low |
| 3 | low | low | high |
| 4 | medium | low | high |

$\text{Dom}(A) = \{\text{low}, \text{medium}, \text{high}\}$

$\text{Dom}(B) = \{\text{low}, \text{high}\}$

$\text{Dom}(C) = \{\text{low}, \text{medium}, \text{high}\}$

$a_1 = A \in \{\text{low}\} \wedge B \in \{\text{low}\} \wedge C \in \{\text{low}\}$

$a_2 = A \in \{\text{medium}\} \wedge B \in \{\text{low}\} \wedge C \in \{\text{high}\},$

$r = a_1 \wedge a_2 = A \in \{\text{low}, \text{medium}\} \wedge B \in \{\text{low}\} \wedge C \in \{\text{low}, \text{high}\}$

Metoda II: przeszukiwanie podzbiorów

Każdy element zbioru danych x_i odpowiada regule $r(x_i)$ – takiej, która wybiera dokładnie ten element. Tworzymy reguły postaci:

- $r(x_{10}) \vee r(x_{31})$,
- $r(x_1) \vee r(x_{45}) \vee r(x_{321}) \vee r(x_{1421}) \vee r(x_{2352}) \vee r(x_{31002})$
- itp.

wybierając najlepsze.

| index | A | B | C |
|-------|--------|------|------|
| 0 | low | high | low |
| 1 | low | low | low |
| 3 | low | low | high |
| 4 | medium | low | high |

$\text{Dom}(A) = \{\text{low}, \text{medium}, \text{high}\}$

$\text{Dom}(B) = \{\text{low}, \text{high}\}$

$\text{Dom}(C) = \{\text{low}, \text{medium}, \text{high}\}$

$a_1 = A \in \{\text{low}\} \wedge B \in \{\text{low}\} \wedge C \in \{\text{low}\}$

$a_2 = A \in \{\text{medium}\} \wedge B \in \{\text{low}\} \wedge C \in \{\text{high}\},$

$r = a_1 \wedge a_2 = A \in \{\text{low}, \text{medium}\} \wedge B \in \{\text{low}\} \wedge C \in \{\text{low}, \text{high}\}$

Obie metody wymagają:

- szybkiego liczenia funkcji *score* (wiele reguł do sprawdzenia);
- efektywnej implementacji algebry reguł (wiele reguł do skonstruowania);
- stosowania heurystycznych optymalizacji.

Obie metody wymagają:

- szybkiego liczenia funkcji *score* (wiele reguł do sprawdzenia);
- efektywnej implementacji algebry reguł (wiele reguł do skonstruowania);
- stosowania heurystycznych optymalizacji.

W konsekwencji:

- kod będzie się często zmieniał na etapie tworzenia prototypu
- nie wiadomo z góry, która reprezentacja reguł będzie optymalna
- może istnieć więcej niż jeden sposób heurystycznej optymalizacji przeszukania
- może nie istnieć globalnie najefektywniejsze rozwiązanie

Z drugiej strony, opis algorytmu jest bardzo prosty.

Implementacja w Haskellu

Czym jest Haskell?

General-purpose, purely functional programming language with non-strict semantics and strong static typing [\[wikipedia\]](#)

Czym jest Haskell?

General-purpose, purely functional programming language with non-strict semantics and strong static typing [wikipedia]

- *strongly typed*: wszystko ma określony typ; kompilator statycznie sprawdza zgodność typów; brak domyślnych konwersji między typami.

```
pi  :: Double  
sin :: Double -> Double
```

podobnie jak w matematyce: $\pi \in \mathbb{R}$, $\sin: \mathbb{R} \rightarrow \mathbb{R}$

Czym jest Haskell?

General-purpose, purely functional programming language with non-strict semantics and strong static typing [wikipedia]

- *strongly typed*: wszystko ma określony typ; kompilator statycznie sprawdza zgodność typów; brak domyślnych konwersji między typami.

```
pi  :: Double  
sin :: Double -> Double
```

podobnie jak w matematyce: $\pi \in \mathbb{R}$, $\sin: \mathbb{R} \rightarrow \mathbb{R}$

- *pure*: brak zmiennych i efektów ubocznych

```
a = 5  
a = 3      -- to 5 czy 3?!
```

```
f :: Int -> Int -> Double  
f x y = ...    -- wartość f zależy *tylko* od x i y
```

Czym jest Haskell?

General-purpose, purely functional programming language with non-strict semantics and strong static typing [wikipedia]

- *strongly typed*: wszystko ma określony typ; kompilator statycznie sprawdza zgodność typów; brak domyślnych konwersji między typami.

```
pi  :: Double  
sin :: Double -> Double
```

podobnie jak w matematyce: $\pi \in \mathbb{R}$, $\sin: \mathbb{R} \rightarrow \mathbb{R}$

- *pure*: brak zmiennych i efektów ubocznych

```
a = 5  
a = 3      -- to 5 czy 3?!
```

```
f :: Int -> Int -> Double  
f x y = ...    -- wartość f zależy *tylko* od x i y
```

- *lazy evaluation*: wartości są liczone dopiero wtedy, gdy są potrzebne:

```
-- lista kwadratów wszystkich liczb naturalnych  
squares = [x*x | x <- [0..]]  
take 5 squares    -- pierwszych 5 wartości  
-- [0, 1, 4, 9, 16]
```

```
type Rule a = Map Text a
```

- ułatwia prototypowanie: kompilator sam podpowiada co i gdzie jeszcze zmienić;
- mniej błędów w wersji finalnej;
- porządkują proces myślowy.

```
type Rule a = Map Text a
```

- ułatwia prototypowanie: kompilator sam podpowiada co i gdzie jeszcze zmienić;
- mniej błędów w wersji finalnej;
- porządkują proces myślowy.

Łatwo możemy tworzyć nietrywialne typy:

```
data Tree a = Node a [Tree a]
```

Więcej niż jeden typ może być regułą:

```
class RuleType a where
  (<=.) :: a -> a -> Bool -- poset
  (&)   :: a -> a -> a     -- and for rules
  (\\)  :: a -> a -> a     -- sup for rules
```

Więcej niż jeden typ może być regułą:

```
class RuleType a where
  (.<=.) :: a -> a -> Bool -- poset
  (/\\)  :: a -> a -> a     -- and for rules
  (\\/)  :: a -> a -> a     -- sup for rules
```

Zbiory jako reguły:

```
instance RuleType (Set a) where
  a .<= b = a `isSubsetOf` b
  a /\ b = a `intersect` b
  a \\/ b = a `union` b
```

Więcej niż jeden typ może być regułą:

```
class RuleType a where
  (<=.) :: a -> a -> Bool -- poset
  (/\\)  :: a -> a -> a    -- and for rules
  (\\/)  :: a -> a -> a    -- sup for rules
```

Zbiory jako reguły:

```
instance RuleType (Set a) where
  a <= b = a `isSubsetOf` b
  a /\ b = a `intersect` b
  a \\/ b = a `union` b

instance Rule a => RuleType (Rule a) where
  a <= b = ...
  a /\ b = ...
  a \\/ b = ...
```

Więcej niż jeden typ może być regułą:

```
class RuleType a where
  (.<=.) :: a -> a -> Bool -- poset
  (/\)   :: a -> a -> a    -- and for rules
  (\/)   :: a -> a -> a    -- sup for rules
```

Zbiory jako reguły:

```
instance RuleType (Set a) where
  a .<= . b = a `isSubsetOf` b
  a /\ b = a `intersect` b
  a \/ b = a `union` b

instance Rule a => RuleType (Rule a) where
  a .<= . b = ...
  a /\ b = ...
  a \/ b = ...

instance Rule a => RuleType [a] where
  a .<= . b = all $ zipWith (.<=.) a b
  a /\ b = all $ zipWith (/\) a b
  a \/ b = all $ zipWith (\/) a b
```


Więcej niż jeden typ może być regułą:

```
class RuleType a where
  (.<=.) :: a -> a -> Bool -- poset
  (/\)   :: a -> a -> a    -- and for rules
  (\/)   :: a -> a -> a    -- sup for rules
```

Zbiory jako reguły:

```
instance RuleType (Set a) where
  a .<= b = a `isSubsetOf` b
  a /\ b = a `intersect` b
  a \/ b = a `union` b

instance Rule a => RuleType (Rule a) where
  a .<= b = ...
  a /\ b = ...
  a \/ b = ...

instance Rule a => RuleType [a] where
  a .<= b = all $ zipWith (.<=.) a b
  a /\ b = all $ zipWith (/\) a b
  a \/ b = all $ zipWith (\/) a b
```

Reprezentacja bitowa:

```
instance RuleType Bool where
  a .<= b = b `implies` a
  a /\ b = a && b
```

Więcej niż jeden typ może być regułą:

```
class RuleType a where
  (.<=.) :: a -> a -> Bool -- poset
  (/\)   :: a -> a -> a    -- and for rules
  (\/)   :: a -> a -> a    -- sup for rules
```

Zbiory jako reguły:

```
instance RuleType (Set a) where
  a .<= b = a `isSubsetOf` b
  a /\ b = a `intersect` b
  a \/ b = a `union` b

instance Rule a => RuleType (Rule a) where
  a .<= b = ...
  a /\ b = ...
  a \/ b = ...

instance Rule a => RuleType [a] where
  a .<= b = all $ zipWith (.<=.) a b
  a /\ b = all $ zipWith (/\) a b
  a \/ b = all $ zipWith (\/) a b
```

Reprezentacja bitowa:

```
instance RuleType Bool where
  a .<= b = b `implies` a
  a /\ b = a && b

instance RuleType BitArray where
  a .<= b = not b | a
  a /\ b = a & b
```

Parametryczny polimorfizm + purity

```
searchRules :: RuleType a, WithScore a =>
  -> (a -> Bool) -- f. przycinająca
  -> Best a       -- najlepsze reguły
  -> Tree a       -- przestrzeń do przeszukania
  -- codomain
  -> Best a       -- nowe najlepsze reguły
```

Implementacja algorytmu wykorzystuje tylko ogólne cechy argumentów, nie konkretne reprezentacje, tu:

- algebra reguł (\leq, \wedge);
- dodawanie nowego elementu do zbioru najlepszych reguł.

Parametryczny polimorfizm + purity

```
searchRules :: RuleType a, WithScore a =>
-> (a -> Bool) -- f. przycinająca
-> Best a      -- najlepsze reguły
-> Tree a      -- przestrzeń do przeszukania
-- codomain
-> Best a      -- nowe najlepsze reguły
```

Implementacja algorytmu wykorzystuje tylko ogólne cechy argumentów, nie konkretne reprezentacje, tu:

- algebra reguł (\leq , \wedge);
- dodawanie nowego elementu do zbioru najlepszych reguł.

Dzięki temu:

- łatwo eksperymentować z różnymi reprezentacji obiektu (korzystamy z dwóch, dwie czy trzy inne były przetestowane trakcie implementacji);
- łatwiej testować poprawność algorytmu (można np. wybrać najprostszą reprezentację reguł);
- bardziej przejrzysty kod.

Parametryczny polimorfizm + purity

```
searchRules :: RuleType a, WithScore a =>
  -> (a -> Bool) -- f. przycinająca
  -> Best a      -- najlepsze reguły
  -> Tree a      -- przestrzeń do przeszukania
  -- codomain
  -> Best a      -- nowe najlepsze reguły
```

Implementacja algorytmu wykorzystuje tylko ogólne cechy argumentów, nie konkretne reprezentacje, tu:

- algebra reguł (\leq , \wedge);
- dodawanie nowego elementu do zbioru najlepszych reguł.

Dzięki temu:

- łatwo eksperymentować z różnymi reprezentacji obiektu (korzystamy z dwóch, dwie czy trzy inne były przetestowane trakcie implementacji);
- łatwiej testować poprawność algorytmu (można np. wybrać najprostszą reprezentację reguł);
- bardziej przejrzysty kod.

```
searchRules :: RuleType a, WithScore a => Int -> (a -> Bool) -> Best a -> Tree a -> Best a
searchRules 0 _ _ bestK (Node r _) = update r bestK
searchRules d prune bestK (Node r cs) = foldl' (searchRules (d-1) prune) updated children
  where
    children = filter interesting cs
    updated  = update r bestK
    interesting (Node r _) = not $ prune r
```

Możemy oddzielić tworzenie przestrzeni reguł do przeszukania od samego algorytmu przeszukującego:

```
hSpace :: RuleType r => [r] -> r -> Tree r
hSpace [] r = Node r []
hSpace pool r = Node r $ filter notNull . map subForest . init . tails $ pool
  where
    subForest (u:us) = hSpace us (r /\ u)
    notNull (Node d _) = not . isNull $ d
```

tworzy w praktyce nieskończone drzewo reguł do przeszukania. Możemy je transformować:

```
space = hSpace pool trivial
fmap toScored space -- infinite tree with scores!
```

- liczenie funkcji *score*, z wykorzystaniem pandas/numpy/numexpr było stosunkowo szybkie;
- ale implementacja algebry reguł była okrutnie powolna...
- ...lub bardzo nieczytelna, jeśli chcieć ją zoptymalizować (pythran, etc.);
- mało wydajne zrównoleglanie kodu;
- przez większą złożoność kodu, znacznie trudniejsze eksperymentowanie z różnymi wariantami algorytmu.

- liczenie funkcji *score*, z wykorzystaniem *pandas*/*numpy*/*numexpr* było stosunkowo szybkie;
- ale implementacja algebry reguł była okrutnie powolna...
- ...lub bardzo nieczytelna, jeśli chcieć ją zoptymalizować (*pythran*, etc.);
- mało wydajne zrównoleglenie kodu;
- przez większą złożoność kodu, znacznie trudniejsze eksperymentowanie z różnymi wariantami algorytmu.

Statystyki

- liczba linii kodu: ok 1500 (Haskell) vs 3800 (Python)
- w tym kod bezpośrednio związany z implementacją algorytmu: 540 (Haskell) vs 3000 (Python)
- wersja w Haskellu średnio ok. 10 razy szybsza od pythonowej (single core) i znacznie lepiej zrównoleglająca się (do 32 rdzeni, w pythonie: kilka do kilkunastu).

Integracja z ekosystemem Pythona

Największy problem

Haskell ma ubogi ekosystem bibliotek odczytujących dane z różnych formatów do których łatwo można eksportować z pandas + brak standardowej biblioteki typu pandas

Największy problem

Haskell ma ubogi ekosystem bibliotek odczytujących dane z różnych formatów do których łatwo można eksportować z pandas + brak standardowej biblioteki typu pandas

ARFF

Własna implementacja formatu ARFF (od Weka):

- prosty format tekstowy – niezależny od specyficznych sposobów binarnego kodowania (pandas miewa z tym problemy);
- w przeciwieństwie do csv kolumny mają ściśle określony typ i dziedzinę;
- efekt końcowy: czytanie plików ARFF niewiele wolniejsze od czytania np. HDF5 w pandas;
- niestety konieczna była implementacja ARFF również w Pythonie...

Dedykowany jupyter kernel

The screenshot shows a Jupyter Notebook interface with a Jupyter kernel. The notebook is titled "akdRules" and has a last checkpoint of 24.08.2018. The interface includes a menu bar (File, Edit, View, Insert, Cell, Kernel, Navigate, Help) and a toolbar with icons for running, saving, and other actions. The notebook content is divided into two main sections: "Contents" and "2 Constructing rules from within the notebook".

Contents

- 1 Loading the database
- 2 Constructing rules from within the notebook
 - 2.1 Iterative DFS search
 - 2.2 Beam BFS search
 - 2.3 Data-driven rule search
- 3 Plotting rule sets
- 4 Rule introspection
- 5 Forging rules and rule queries
- 6 Generating rules with filtered atoms

2 Constructing rules from within the notebook

Using default options, generate and test algorithm (top-down search):

```
In [3]: td = dig with atoms
```

```
Out[3]: 10 rules, Lift: 1.771 - 1.904 Score: 0.691 - 0.697 Dim: 2 - 3
```

| rid | rule | dim | cov | p | n | lift | score |
|-------|--|-----|-----|-----|-----|-------|-------|
| @10.0 | Gender: not(Mr, Rev), Nb-of-accompanied-children: (-inf, 3.0] | 3 | 532 | 395 | 177 | 1.797 | 0.697 |
| @9.0 | Gender: not(Mr, Rev), Nb-of-accompanying-adults: (-inf, 1.0] | 3 | 471 | 333 | 138 | 1.904 | 0.696 |
| @7.0 | Gender: not(Capt, Mr, Rev) | 3 | 541 | 357 | 184 | 1.777 | 0.695 |
| @8.0 | Gender: not(Mr, Rev), Nb-of-accompanied-children: (-inf, 6.0] | 3 | 541 | 357 | 184 | 1.777 | 0.695 |
| @6.0 | Gender: not(Mr, Rev) | 2 | 542 | 357 | 185 | 1.774 | 0.695 |
| @5.0 | Gender: not(Mr), Nb-of-accompanied-children: (-inf, 3.0], Nb-of-accompanying-adults: (-inf, 1.0] | 3 | 469 | 331 | 138 | 1.901 | 0.693 |
| @4.0 | Gender: not(Capt, Mr), Nb-of-accompanied-children: (-inf, 3.0] | 3 | 539 | 355 | 184 | 1.774 | 0.693 |
| @3.0 | Gender: not(Mr), Nb-of-accompanied-children: (-inf, 3.0] | 2 | 540 | 355 | 185 | 1.771 | 0.692 |
| @1.0 | Gender: not(Capt, Mr), Nb-of-accompanying-adults: (-inf, 1.0] | 3 | 478 | 333 | 145 | 1.876 | 0.691 |
| @2.0 | Gender: not(Mr), Nb-of-accompanied-children: (-inf, 6.0], Nb-of-accompanying-adults: (-inf, 1.0] | 3 | 478 | 333 | 145 | 1.876 | 0.691 |

2.1 Iterative DFS search

The worst-case scenario has exponential complexity with depth. We implement various heuristics to decrease complexity in real life cases, but their impact depends highly on the structure of dataset. In any case, this guarantee to find the best solution.

```
In [ ]: td_ids = dig best 20 depth 4 ids with atoms
```

- znany interfejs
- pozwala wykorzystać algorytmy wyszukiwania reguł do edycji istniejących reguł – przydatne gdy dodaje się wiedzę domenową.

Podsumowanie

Dzięki dopasowaniu specyfiki problemu i cech narzędzia, udało się uzyskać:

- wydajniejszy proces tworzenia narzędzia
- kod łatwiejszy w utrzymaniu
- łatwość tworzenia eksperymentalnych wariantów
- większą szybkość działania
- łatwiejsze testowanie
- większa satysfakcja z pracy

Choć bywały trudniejsze momenty:

- brak wsparcia w ekosystemie
- nie jest to droga dla początkujących
- trzeba uważać na przesadną abstrakcję

Dziękuję za uwagę